

AI의 몫, 사람의 몫


김성하 · Sung Ha Kim · [Carlos.space](https://carlos.space)

24.02 - 동국대학교 융합에너지신소재공학과 졸업

26.08 - 리얼월드 RD팀 파일럿

Phone - 010 - 7605 - 7605

E-mail - kimsh5491@naver.com



GitHub

CarlosKim-1997 - Overview

CarlosKim-1997 has 8 repositories available. Follow their code on GitHub.



AI와 무엇을, 어디까지, 그리고 어떻게

저는 아래의 프로세스를 통해 문제를 해결합니다.

01	02	03	04	05	06	07
STAGE 1	STAGE 2	STAGE 3	STAGE 4	STAGE 5	STAGE 6	STAGE 7
Problem	Hypothesis	AI Role	Evaluation	Failure Check	Boundary Set	Better Next Time
문제 사항과 병목 정의	직관을 기반한 검증 가설 수립	AI에 논리 해석, 레퍼런스 수집, 제안자 역할 부여	백 마디 말보다 사실 기반 검증	문제 정의 / 가설 / 조사 결과 점검	정리된 정보를 기 반으로 결론 경계 확정	반복 프로세스 및 차후 개선 가시화

CASE 01	CASE 02	CASE 03	CASE 04
ReDiscovery	Hermeneus	Repository-Governance	Robot Troubleshooting
AI와 함께 하는 '이론 재발견 데일리 웹게임'	AI가 전달하는 '손실 없는 대화맥락'	Agent가 달라져도, 일은 일관적으로 'Agent의 Repo 관리 메뉴얼'	직장에서 로봇 문제를 만났을 때, '재현 가능한 문제 찾기'

AI가 게임 마스터가 되기까지


제시되는 조건에 따라 과거의 통찰/이론을 재발견하는 데일리 추론 게임

플레이어 입력을 판단하거나, 개인의 이해 진전도에 따른 힌트를 위해 'LLM 기반 semantic Judge'를 도입했고, 점차 고도화했습니다.

EVIDENCE

124-CASE ADVERSARIAL EVALUATION

20 AUTHORED SEED + 104 MESSY/ADVERSARIAL VARIANTS



프롬프트 + Semantic layer + 모델 변경을 통해
성능 향상을 경험했지만...

PREMATURE LOCK (치명적 실패 지표)

'넘겨 줬기' 발생

Judge	Premature Lock
v1	0
v2	0
v3 Luna	2
v3 Terra	2

Macro F1은 0.89까지 상승했지만, 충분한 추론 증거가 없는 플레이어를 성급하게 정답으로 확정 짓는 치명적 결함 발생

더 좋은 모델 대신, 구조를 다시 설계했습니다

'AI 호출 = 불확실성을 가진 외부 실행'으로 보고, 통제 가능한 환경으로 감쌌습니다.

BEFORE ARCHITECTURE

User Answer → LLM judge → Final Judgment

LLM이 최종 합격/불합격 및 게임 종료 결정을 직접 소유
모델의 과신이나 환각이 그대로 사용자 경험 실패로 직결됨
결과 검증 및 경계 통제 불가능

AFTER ARCHITECTURE

User Answer → Semantic Sensor → Structured State →
Deterministic Policy → Approved Guidance

핵심 아이디어: LLM을 Semantic Sensor로 제한하고, Structured State와
Deterministic Policy가 Approved Guidance를 선택하도록 설계

MERIT 1 : BOUNDARY CONTROLS

사용자 입력을 Semantic하게 판별해 LLM 호출 방향성 결정
LLM 호출 횟수 / 답변 품질 통제 가능

MERIT 2 : OPERATIONAL RELIABILITY

입력에 따라 State를 저장하고, Policy를 기반으로 결과를 작성하여
일관된 사용자 경험 제공 + 정보 관리 용이성 확보

RESULT : VERIFICATION

Vitest 923 / 923 passed ·

Playwright 101 passed / 1 skipped

Session budget ≤ 8 paid Judge admissions per official session

Link : rediscovery.space * 09/28 기준 테스트 배포 중입니다.

사람 사이의 전달/이해 병목을 AI로 해소할 수 있을까?

AI와 아이디어를 정리했는데, 이걸 어떻게 그대로 전달하지?

맥락을 손실 없이 전달하기 위해 아래의 과정으로 맥락을 기록했습니다.

01

Raw Conversation

원본 대화 스트림

02

Normalized Stream

의미 단위 정규화

03

Draft Handoff

가정·대안 추출

04

Creator Review

검토 및 승인

RECEIVER AI ANSWER MODEL

- **SUPPORTED** — 정리된 Handoff 원문에 명시된 근거
- **DERIVED** — 맥락에서 직접 도출되는 추론
- **OPEN** — 기각되었거나 미해결된 논점
- **UNKNOWN** — 전달된 맥락에 없어 답변할 수 없음

LLM의 사용자에게 supportive한 성향이 의미 전달에 방해가 될 수 있기에, 기록된 증거와 맥락을 기반으로만 설명하고 응답하도록 설계했습니다.

특히 Receiver AI가 사용자의 질문에 끌려가 없는 정보를 그럴듯하게 보충하지 않도록 유의했습니다.

GITHUB LINK

CarlosKim-1997/
hermeneus

0 0 0
Issues Stars Forks



GitHub – CarlosKim-1997/H...

Contribute to CarlosKim-1997/Hermeneus development ...

코딩 에이전트의 Repo 관리 매뉴얼

매번 AI가 코드를 전부 읽는 것은 비효율적이니,
대화 세션에 흠어지는 결정·제약·현재 상태를 Repository 안에 구조화했습니다.

GOVERNANCE STRUCTURE

바뀌지 않는 설계 철학 - Principles

설계 결정 목록 - Decisions

제한 사항 - Constraints

미정 상태인 의문들 - Open Questions

현재 상태 기록 - Current State

작업 기록 - Tasks

GITHUB LINK

CarlosKim-1997/
repository-governance

0 0 0
Issues Stars Forks



GitHub



GitHub – CarlosKim-1997/reposito...

Contribute to CarlosKim-
1997/repository-governance...

BETTER NEXT TIME

별도 Repository에 기록 구조 포맷을 기재하여 이후에도 동일한 체계를 사용할 수 있도록 했습니다.

현실의 실패를 검증 가능한 문제로

아래의 방법으로 현 업무에서 로봇/장비의 오작동에 대응하고, Physical AI의 행동 평가를 수행합니다.

01	02	03	04
Observation	Hypotheses	Experiments	Evidence
반복되는 문제를 관찰	동작 원리와 맞물리는 원인을 토대로 가설을 만듭니다.	AI로 원인 후보 확장·레퍼런스를 탐색, 최소 실험을 설계합니다.	증거로 원인 후보를 추립니다.

TROUBLESHOOTING PRINCIPLE

빈번하게 발생하는 로봇 문제에 대한 원인 후보 우선순위를 기록 및 실적용 중입니다.

또한 로봇 트러블슈팅 문제 classification과 AI가 이후 유사 케이스에 참조할 수 있는 팀 단위 기록체계를 구성 중입니다.

EXAMPLE CASE

한 바구니에 든 물건들을 다른 바구니로 옮기는 Task에서, 특정 기점 이후 반복적으로 빈 바닥을 타겟하는 문제가 발생했습니다.

관찰 결과, 로봇이 촬영하는 Wrist cam에 바구니 바닥의 반사광이 고정적으로 나타남을 확인했고, VLA 학습 특성 상 학습에 쓰이는 압축된 영상 데이터에서 목표 물건의 흰색 라벨링과 반사광이 동일하게 하얀 픽셀로 인식될 수 있다는 가설을 세웠습니다.

이후 바구니 바닥을 보강해 반사광이 나타나지 않도록 하자, 관련 증상이 사라져 원인을 확정지을 수 있었습니다.

기타 개인 프로젝트 및 기술 스택

B2C SERVICE



CalmMail

Electron · React · TypeScript · SQLite · Gmail/IMAP · local/cloud AI
Rule base/로컬LLM 기반 개인 메일함 관리 프로그램입니다.

메일함 체크 후 브리핑 / 확인 우선 순위 리스트 생성 / 중요 메일 알림 등을 로컬 환경에서 보안 걱정 없이, 조용히 지원합니다.

CarlosKim-1997/
CalmMail

Issues

Stars

Forks

 GitHub

GitHub – CarlosKim-1997/C...

Contribute to CarlosKim-1997/CalmMail development by...

AI SYSTEMS

LLM evaluation, RAG, structured output, provider adapters, AI Gateway, semantic state

SOFTWARE

Python, TypeScript, Next.js, React, PostgreSQL, Supabase, Electron

POC

AI Workflow Orchestrator

LLM으로 메일 판별 → 기존 업무 체계 → Jira / Slack / Email 티켓 생성

Secure Hybrid RAG Assistant

보안 유지를 위해 질문 의도 파악은 LLM API, 답변 생성은 Local LLM으로 분리한 사내 규약 / 메뉴얼 어시스턴트

Kubernetes Security RAG

RAG 기반 버전 별 K8S 디버깅 및 보안 관련 체크리스트 생성기

VERIFICATION

Vitest, Playwright, CI, adversarial evaluation, deterministic testing

AI ENGINEERING

Coding agents, repository governance, MCP workflows

AI가 자신의 몫을 해내도록 환경을 구성하고, 사람에게 연결합니다.

AI에는 해석·탐색·반복을, 시스템에는 경계와 검증을, 사람에게는 목적과 최종 판단을.

System	AI의 몫	사람의 몫
ReDiscovery	의미 해석, 학습 상태 감지	무엇을 정답으로 확정할지의 기준
Hermeneus	맥락 추출·근거 기반 설명	무엇을 공식 맥락으로 승인할지 결정
Repository Governance	위임된 작업 수행·제안	원칙·결정·제약의 최종 권한
Physical AI	원인 후보 확장·레퍼런스 탐색	실험 설계·증거 해석·원인 판단
CalmMail	필요할 때 분석·정리	메모리 변경과 권한 부여